

Práctico 1 – Análisis y Visualización de Datos

Objetivo

Realizar una **exploración inicial** del dataset de ventas para comprender su estructura, distribución de variables relevantes (como ventas, fechas, productos, puntos de venta, clientes) y descubrir **patrones, tendencias, estacionalidades o anomalías**.

El entregable deberá ayudar a **formular hipótesis** que orienten los siguientes pasos del proyecto de análisis o modelado.

Entregables requeridos

El trabajo se debe subir en un repositorio público de GitHub (archivos en caso de no ser posible en repositorio). Vemos una estructura mínima de ejemplo:

```
practico_1_eda/  
|  
├─ data/  
|   └─ ventas.csv           # Dataset base  
├─ practico_1_eda.ipynb    # Notebook con el desarrollo completo  
|  
├─ img/                    # Imágenes generadas por  
|                           visualizaciones (opcional)  
|  
└─ README.md               # Documento explicativo del práctico
```

✓ Contenido obligatorio del notebook

1. Carga del dataset

- Carga inicial y verificación de estructura (shape, tipos, nulos).

2. Limpieza básica

- Manejo de nulos o outliers si es necesario.

3. Análisis descriptivo

- Métricas de resumen: medias, medianas, desvíos, conteos.

4. Visualizaciones clave

- Evolución temporal de ventas.
- Distribución por día de semana, mes o estacionalidad.
- Análisis por punto de venta, producto y/o cliente.
- Relación entre frecuencia de compra y volumen de ventas.

5. Análisis de granularidad temporal

- Realizar un **estudio sobre la granularidad más adecuada** para agrupar los datos: diario, semanal, mensual u otra.
- Justificar la elección en base a visualizaciones o métricas (variabilidad, estacionalidad, ruido, etc.).
- Este paso es **clave para decisiones de modelado y forecast futuras**.

6. Visualización

- Visualizaciones y gráficas pertinentes

7. Hipótesis iniciales y hallazgos

- Comentarios sobre comportamientos relevantes, anomalías y lo que podría investigarse en prácticas futuras.

Preguntas mínimas a responder:

1. Cuántas filas y columnas tiene el dataset? Qué representan?
2. Qué porcentaje de valores faltantes hay por columna? Cómo podrían imputarse o tratarse las más problemáticas?
3. Qué tipo de variables (numéricas, categóricas, fechas) están presentes? Cuáles parecen claves para el análisis comercial?

4. Hay columnas redundantes?
5. Qué nivel de granularidad tiene el dataset: venta por ítem, por pedido, por factura?
6. Cuáles son los productos más vendidos en términos de cantidad?
7. El producto menos vendido se vende lo suficiente para tenerlo en cuenta en un sistema de recomendación?
8. El producto más vendido se vende en todos los puntos de venta?
9. Cuáles son los puntos de venta con mayor cantidad de ventas?
10. Cuáles son los puntos de venta con mayor facturación?
11. Como se distribuye la variable precio de los productos?
12. Como se distribuye la variable de cantidad de los productos?
13. La variable de descripción está estandarizada?
14. Qué rango temporal está presente en el dataset?
15. Todos los puntos de venta tienen registro dentro del mismo intervalo temporal?
16. Qué nivel de granularidad temporal debo manejar para no tener un exceso de series temporales incompletas?

Herramientas sugeridas

- `Pandas`
- `Matplotlib`
- `Seaborn`



Contenido del README del repositorio (Opcional)

El `README.md` debe incluir:

- Breve descripción del objetivo del práctico.
- Instrucciones para correr el notebook (requisitos, librerías, etc.).
- Comentarios sobre los principales hallazgos y qué hipótesis podrían orientar modelos futuros.