

Práctico 2 – Análisis Exploratorio y Curación de Datos

Objetivo

Realizar la depuración, transformación y validación del dataset para asegurar su calidad antes de iniciar el modelado. Este práctico se enfocará en preparar una base de datos sólida, coherente y con el menor ruido posible para los modelos de clustering, recomendación y predicción de demanda.

Contenido obligatorio del notebook

1. Definición de granularidad principal

- Definir granularidad temporal a nivel PDV + SKU + fecha en función a lo observado en Practico 1. **(Recomendado: por mes)**
- Justificar la elección.
- Generar dataset agregado con valores por unidad de análisis: total ventas, cantidad, frecuencia, etc.

Recomendaciones para tratar series incompletas

- **Eliminar series con baja completitud:**
 - Recomendación: filtrar series con más del 20% - 30% de datos faltantes (huecos en las series).
Estas series pueden introducir ruido y dificultar el entrenamiento de modelos robustos. (Depende del algoritmo utilizado)
- **Imputar valores faltantes si se desea conservar series:**
 - Técnicas sugeridas:
 - Forward Fill (último valor válido)
 - Rolling mean o Moving average

- Interpolación lineal (cuando sea razonable)
- Documentar la técnica elegida y justificar según el caso.

2. Depuración de datos

- **Eliminación de duplicados**
- **Detección y tratamiento de valores faltantes**
 - Por columna: porcentaje de nulos, estrategia de imputación o eliminación
- **Detección de outliers**
 - Para variables clave como precio, cantidad, facturación

4. Transformación de variables (en casos que sea necesario)

- Conversión correcta de fechas
- Creación de nuevas columnas.
- Conversión de tipos correctos (por ejemplo, **object** a **category**)

5. Deflactación de montos

- Ajuste de precios a moneda constante usando IPC (índice de precios)
 - Documentar la fuente y metodología de ajuste

6. Estandarización y escalamiento

- Aplicar **normalización o estandarización** a valores monetarios y cantidades
 - **StandardScaler** o **MinMaxScaler**
 - Justificar cuál se elige y por qué

7. Verificación de consistencia

- Verificar integridad de claves primarias (PDV, SKU, fechas)

8. Documentación de decisiones

- Explicar **por qué** se eliminan, imputan o transforman columnas
 - Evaluar **impacto** de cada paso con métricas comparativas
-

Recomendaciones adicionales

- **Visualizar** el antes y después de la limpieza para mostrar mejoras
 - Documentar TODO en el README.md
 - Opcional: crear función reutilizable `limpiar_dataset(df)` en Python
-